# MedFlow — Documento de Especificação, Requisitos e Épicos

**Sistema Integrado de Gestão de Agenda e Prontuário para Clínicas Solo e de Pequeno Porte**

| CAMPO | VALOR |
|---|---|
| Projeto | MedFlow — Software Factory |
| Documento | Especificação de Requisitos & Épicos (derivado do Status Report I / AV1 + decisões da equipe) |
| Disciplina | Fábrica de Software / Atividades Interdisciplinares de Extensão IV (APIExt IV) |
| Semestre | 2026/2 — entrega final AV2: 15/12/2026 |
| Metodologia de gestão | Scrumban (sprints quinzenais + Kanban com limite de WIP) |
| Stack | **React (Vite) + Tailwind + BlockNote** (front/editor) · **ElysiaJS (Bun/TypeScript)** (back — gera o PDF) · SQlite + Prisma (dados) · **Integração Sintesy — api.sintesy.me (API B2B)** (transcrição, modelo `stt-low`) · **WAHA self-hosted** (WhatsApp — 1 sessão por clínica) · **gorouter** (extração de tópicos) · GitHub Actions + Docker (CI/CD) · Figma (prototipação) |

## Registro de alterações vs. Status Report I (AV1)

| # | MUDANÇA | JUSTIFICATIVA |
|---|---|---|
| 1 | Back-end: NestJS → **ElysiaJS (Bun)** | Performance e tipagem end-to-end (Eden Treaty); runtime Bun leve para API de baixa latência |
| 2 | Front-end: Next.js → **React (Vite SPA)** | SPA não precisa de SSR (app interno de clínica); simplifica build |
| 3 | Transcrição: Whisper API → **Integração com a plataforma Sintesy (api.sintesy.me)** | Reuso de serviço existente com STT de alta precisão em PT-BR; remove custo/complexidade de gerenciar provider de voz direto |
| 4 | Extração de tópicos permanece no MedFlow (prompt engineering sobre o texto transcrito) | Ver Seção 5 |
| 5 | Confirmação de consulta: e-mail + "webhook gratuito" → **WhatsApp via WAHA self-hosted** (1 sessão por clínica, número dedicado conectado por QR code) | Canal onde o paciente está; sem gateway pago; número da clínica em vez do pessoal reduz risco de bloqueio |
| 6 | Assinatura de documentos: avançada/hash → **assinatura eletrônica simples** | Simplicidade e aderência à rotina real (impressão + punho quando exigido) |

| | | |
|---|---|---|
| 7 | Editor de templates: texto com sintaxe → **editor visual BlockNote** com chips de campos, logo, cabeçalho/rodapé e preview A4; **PDF gerado no back-end** | Usabilidade sem atrito: o profissional não digita sintaxe |
| 8 | Permissões do recepcionista: nenhuma → **leitura de Prescrições e Exames** | Recepção precisa baixar/enviar documentos ao paciente |
| 9 | Sessão: JWT com expiração → **JWT sem expiração** | Simplicidade; o usuário permanece logado no consultório |
| 10 | Auth da transcrição: conta de usuário do Sintesy → **API B2B própria do Sintesy** (API key por aplicação/clínica) | Reuso da plataforma como serviço; atende o MedFlow e habilita outros produtos sem credencial de pessoa física |
| 11 | Extração de tópicos: LLM genérico → **gorouter (combo próprio)**, atrás da abstração `ExtractionProvider` | Controle de custo/latência e troca de modelo sem alterar o pipeline clínico |
| 12 | Áudio da anamnese: formato livre → **MP3, até 500 MB**, com truncamento controlado acima do limite | Padroniza captura/upload e evita recusa do endpoint por formato/tamanho |
| 13 | Quota: bloqueio por limite → **sem bloqueio; medição de custo por clínica** (modelo `stt-low` ) | Não trava a rotina clínica no MVP e mantém a base para cobrança futura |
| 14 | WhatsApp: sessão por profissional → **1 sessão WAHA por clínica** | Uma conexão/QR por clínica; menos recursos e suporte mais simples |

# 1. Visão Geral do Produto

## 1.1 Problema

Clínicas solo e de pequeno porte sofrem com:

1. **No-shows e sobreposições de agenda** — faltas sem aviso e conflitos de horário geram ociosidade e prejuízo operacional direto.
2. **Documentação clínica dispersa** — prontuários, anamneses e receitas em formatos variados, sem padronização nem rastreabilidade.
3. **Atenção dividida no atendimento** — profissional perde contato visual com o paciente ao digitar em telas extensas durante a consulta.

## 1.2 Solução

- **Agenda com foco na ação**: grade semanal/diária dinâmica, status visual e atalho de 1 clique para a Ficha Completa do Paciente.
- **Centralização 360°**: prontuário cronológico contínuo + biblioteca de templates reutilizáveis.
- **Transcrição Inteligente**: ditado de voz com extração semântica direcionada estritamente aos tópicos pré-configurados pelo profissional — STT fornecido pela plataforma **Sintesy** (Seção 5).

### 1.3 Objetivo Geral

Desenvolver e disponibilizar um sistema web integrado para clínicas pequenas e consultórios solo, estabelecendo um fluxo ágil centrado na gestão inteligente de agenda, na centralização da ficha do paciente e na facilitação documental via templates e transcrição inteligente de anamnese.

### 1.4 Fora de Escopo (Fases Futuras)

| ÁREA | EXCLUSÕES EXPLÍCITAS |
|---|---|
| Agenda | Gateways pagos de telefonia/SMS corporativo |
| Prontuário | Migração legada de sistemas hospitalares complexos (TASY/MV) |
| Documentos | Assinatura digital ICP-Brasil (token/nuvem); editor de posicionamento livre tipo Canva |
| Transcrição | Diagnóstico autônomo / decisão clínica por IA (a IA é estritamente redatora) |
| Financeiro | Faturamento e glosa TISS/TUSS, módulo fiscal/NF-e |

## 2. Papéis e Permissões

### 2.1 Papéis de usuário do sistema

| PAPEL | PERMISSÕES |
|---|---|
| **Médico** | Acesso total: agenda própria, prontuários, templates, transcrição, emissão de documentos, configurações da clínica |
| **Recepcionista** | Agenda (criar/mover/cancelar, encaixes, bloqueios), cadastro de pacientes, envio de mensagens WhatsApp e **leitura de Prescrições e Exames** (para baixar e enviar ao paciente). **Sem acesso** a anamnese, evolução clínica e demais conteúdos do prontuário |

## 3. Requisitos Funcionais

### Módulo A — Gestão de Agenda

| ID | REQUISITO | PRIORIDADE (MOSCOW) |
|---|---|---|
| RF-A1 | Grade de agenda diária e semanal com visualização clara de intervalos e status | Must |
| RF-A2 | Criação rápida de horários de consulta | Must |

| | | |
|---|---|---|
| RF-A3 | Bloqueios de horário (ausências, intervalos) | Must |
| RF-A4 | Encaixes operacionais (marcar fora do slot padrão, sem sobrepor atendimento existente) | Must |
| RF-A5 | Controle visual de status: **Agendado, Confirmado, Em Espera, Em Atendimento, Concluído, Cancelado** | Must |
| RF-A6 | Transição em 1 clique do agendamento para a Ficha Completa do Paciente | Must |
| RF-A7 | Impedir sobreposições: trava no nível de transação do banco (constraints SQlite), não apenas na aplicação | Must |
| RF-A8 | Lembrete e confirmação de presença por **WhatsApp** (WAHA self-hosted, 1 sessão por clínica, número dedicado da clínica) com atualização automática do status na agenda. Ver Seção 3.1 | Should |
| RF-A9 | Registro de faltas (no-show) para histórico do paciente | Should |

## 3.1 Detalhamento do RF-A8 — confirmação via WhatsApp (WAHA)

**Objetivo:** atacar a causa nº 1 do problema (no-show) no canal onde o paciente está, sem custo de gateway de SMS.

- **Conexão:** a clínica conecta **um número de WhatsApp** ao MedFlow lendo um **QR code** (Configurações → Integrações → WhatsApp). A mensagem sai do celular/número da clínica — sem provedor pago e sem número virtual.
- **Infraestrutura: WAHA self-hosted** (container Docker do próprio MedFlow), com **armazenamento persistente** da sessão (a sessão não pode ser perdida a cada restart do container).
- **Modelo de sessão (decisão): 1 sessão WAHA por clínica** ( `WhatsappSession` 1:1 com Clínica). Todos os usuários autorizados da clínica (médico e recepção) enviam pelo mesmo número; o número é **dedicado da clínica**, não o pessoal do profissional.
- **Disparo:** ao criar a consulta e/ou em marco anterior ao atendimento (ex.: 24h antes), o MedFlow envia a mensagem com data, hora, profissional e o pedido de confirmação. O texto da mensagem é editável pela clínica.
- **Resposta do paciente:** chega ao MedFlow pelo **webhook do WAHA** e atualiza o status do agendamento na grade (Confirmado / Cancelado).
- **Interpretação da resposta (palavras-chave + variações):** antes da comparação a mensagem é normalizada (minúsculas, sem acentos, sem pontuação, espaços colapsados) e comparada com uma lista de termos.
  - **Confirmação:** `SIM` , `S` , `CONFIRMO` , `CONFIRMADO` , `CONFIRMAR` , `1` , `OK` , `VOU` , `ESTAREI` (e variações próximas).
  - **Cancelamento:** `NÃO` , `NAO` , `N` , `CANCELAR` , `CANCELO` , `CANCELADO` , `2` , `NÃO VOU` , `NAO VOU` , `NÃO PODEREI` , `NAO PODEREI` .
  - A lista é **configurável pela clínica** e evolui conforme respostas reais observadas.
- **Resposta ambígua:** se não for reconhecida como sim/não, o agendamento vai para a fila **"aguardando confirmação manual"** e aparece para a recepção resolver — nunca fica em estado indefinido silencioso.
- **Estado da mensagem:** o sistema não considera enviado só porque o WAHA aceitou a chamada — há estados `pendente → enviando → enviada → falhou` , com fila de pendentes e reenvio manual. Mensagens antigas não são reenviadas automaticamente (uma confirmação de "amanhã" não pode sair dias depois).

- **Número bloqueado/desconectado (WAHA usa API não oficial):** o painel mostra `conectado` / `desconectado` / `aguardando QR`; a clínica é alertada; mensagens pendentes ficam em fila (nada é perdido em silêncio); a reconexão é feita por novo QR code; o plano B documentado é a **WhatsApp Cloud API oficial**.
- **Não haverá** "webhook gratuito" nem e-mail no MVP (decisão registrada).
- **Risco conhecido:** WAHA usa API não oficial do WhatsApp — ver Seção 8.

## Módulo B — Ficha do Paciente & Prontuário

| ID | REQUISITO | PRIORIDADE |
|---|---|---|
| RF-B1 | Cadastro de paciente: dados pessoais, convênio/plano de saúde, dados de contato | Must |
| RF-B2 | Visão 360° unificada: dados pessoais + convênio + histórico de atendimentos em uma tela | Must |
| RF-B3 | Linha do tempo cronológica contínua dos atendimentos com anotações de evolução | Must |
| RF-B4 | Repositório de anexos clínicos e exames laboratoriais (PDF/JPG) | Must |
| RF-B5 | Busca de pacientes **livre e incremental** por nome, CPF e telefone, com normalização (acentos, caixa e pontuação). Ver Seção 3.2 | Should |

## 3.2 Detalhamento do RF-B5 — busca de pacientes

**Decisão:** busca livre (LIKE/ `ILIKE` parcial) e **incremental** — resultados aparecem enquanto o usuário digita, com **debounce de 250–300 ms** no front para não disparar requisição a cada tecla.

| CAMPO | REGRA |
|---|---|
| **Nome** | Busca parcial por qualquer trecho ( `"maria oli"` → Maria Oliveira Santos); ignora caixa e **acentos** (normalização `unaccent` /coluna espelho) |
| **CPF** | Comparação sobre valor **normalizado** (só dígitos): `123.456.789-00`, `123 456 789 00` e `12345678900` buscam igual. Exibição sempre **mascarada** na lista de resultados |
| **Telefone** | Normalizado (só dígitos, sem espaços/parênteses/hífens, com tratamento de DDI `+55` ); aceita busca parcial |

**Implementação:** colunas normalizadas dedicadas ( `nome_normalizado`, `cpf_normalizado`, `telefone_normalizado` ) mantidas por trigger/aplicação, com **índices** (CPF único e indexado; nome com índice trigram). Não aplicar `LIKE` direto nos campos originais a cada consulta.

**Desambiguação:** cada resultado mostra **nome completo, CPF mascarado, data de nascimento e telefone** — para o usuário confirmar que é o paciente certo antes de abrir a ficha (1 clique → Ficha Completa, RF-A6/RF-B2).

## Módulo C — Templates & Documentos

| ID | REQUISITO | PRIORIDADE |
|---|---|---|

| | | |
|---|---|---|
| RF-C1 | **Editor visual de documentos** (BlockNote): folha A4, texto rico, blocos, logo, cabeçalho/rodapé, divisores e campos automáticos, com preview fiel ao PDF | Must |
| RF-C2 | Inserção de campos pelo botão **"Inserir campo automático"** com catálogo fechado (Paciente, Médico, Atendimento, Clínica); o usuário **nunca digita sintaxe** | Must |
| RF-C3 | Emissão ágil de **Receituário simples** por template | Must |
| RF-C4 | Emissão de **Receituário de controlados** com campos exigidos por legislação | Must |
| RF-C5 | Emissão de **Laudo médico** por template | Must |
| RF-C6 | Central de Documentos: **PDF gerado no back-end**, arquivado por paciente e por atendimento | Must |
| RF-C7 | **Assinatura eletrônica simples**: identificação do autor (nome + CRM) no PDF, registro de autor/data/hora e log de auditoria. Sem ICP-Brasil e sem hash/QR no MVP | Must |
| RF-C8 | **Campo de texto livre** no template, preenchido pelo médico no momento da emissão (ex.: o corpo da prescrição) | Must |
| RF-C9 | **Preview com paciente fictício** durante a edição do template | Should |
| RF-C10 | Imutabilidade: o documento emitido é guardado como snapshot (valores preenchidos + PDF); editar o template não altera documentos já emitidos | Must |

## 3.3 Detalhamento do editor de templates (RF-C1/C2/C8/C9)

Decisão de produto: **simples, amigável e sem atrito**. O médico monta o documento visualmente; a sintaxe é invisível.

**O que o editor tem**

- Folha A4 com visualização exatamente igual ao PDF final (WYSIWYG).
- Texto normal, negrito, tamanho de fonte, espaçamento e alinhamento (esquerda/centro/direita).
- Logo da clínica, cabeçalho e rodapé, linhas/divisores.
- Campos automáticos inseridos como **chips visuais clicáveis** ( `[ Nome do paciente ]` ), que podem ser apagados, duplicados ou movidos dentro da linha/bloco.
- Movimentação **dentro de regiões controladas** (blocos) — sem posicionamento livre em pixel.

**O que o editor não tem (fora do MVP)**

- Drag-and-drop absoluto, coordenadas, sobreposição livre de elementos e redimensionamento arbitrário (estilo Canva). Motivo: explode a complexidade de renderização de PDF, quebra de página e impressão sem atender a nenhum requisito.

**Como o campo é inserido**

1. O médico clica em **+ Inserir campo** → escolhe o grupo → escolhe o campo.

2. No editor aparece o chip amigável: `Paciente: [ Nome do paciente ]`.
3. Internamente é armazenado `{{paciente.nome}}` — o usuário nunca vê nem digita a sintaxe.

**Catálogo de campos (MVP) — decidido**
Todos os campos abaixo entram no catálogo. **Essenciais** bloqueiam a emissão quando o documento exigir; **complementares** são opcionais (se vazios, o chip simplesmente não aparece no PDF — nunca `undefined` / `null` / `N/A`).

| GRUPO | ESSENCIAIS (OBRIGATÓRIOS) | COMPLEMENTARES (OPCIONAIS) |
|---|---|---|
| Paciente | Nome completo · CPF · Data de nascimento · Telefone · Endereço · Cidade · UF | Idade · Convênio · Número da carteirinha · Sexo · E-mail · Peso · Altura · Alergias · Medicamentos · Nome social |
| Médico | Nome · CRM · Especialidade | — |
| Atendimento | Data · Hora · Número do atendimento | — |
| Clínica | Nome · CNPJ · Endereço · Telefone | — |
| Documento | — | Data de emissão · Cidade · UF (quando não vier do endereço da clínica) · Validade do documento |

**Obrigatoriedade por tipo de documento** (não é global — varia por documento):

| TIPO | EXIGE NO MÍNIMO |
|---|---|
| Receita simples | Nome, CPF, data de nascimento do paciente; nome e CRM do médico; data |
| Receita de controlados | Os anteriores + **endereço completo** do paciente (cidade/UF) e do emitente |
| Laudo | Nome, data de nascimento, data do atendimento, nome/CRM/especialidade |
| Documento personalizado | Definido pelo template |

Metadado interno do campo (exemplo):

```
{
  "field": "paciente.cpf",
  "label": "CPF do paciente",
  "type": "text",
  "requiredByDefault": true,
  "requiredFor": ["receita", "receita_controlado", "laudo"]
}
```

**Logo**

- Upload único em **Configurações → Clínica → Identidade visual**.
- No editor: **Inserir → Logo da clínica**, com opções simples de tamanho (pequena / média / grande) e alinhamento (esquerda / centro / direita).

**Campos obrigatórios × opcionais**
Cada campo do catálogo carrega metadados internos:

- `paciente.nome` → tipo: texto · **obrigatório: true**
- `paciente.telefone` → tipo: texto · **obrigatório: false** (se vazio, o chip simplesmente não aparece no documento)

**Validação em três camadas**

| MOMENTO | COMPORTAMENTO |
|---|---|
| Ao salvar o template | Placeholder inválido (ex.: `{{pacient.nome}}` vindo de bug/importação) → template fica com status **"Template com erro"** e não pode ser usado até ser corrigido |
| Na emissão | Campo obrigatório vazio → **bloqueio com mensagem amigável**: "Não é possível emitir este documento. Faltam os seguintes dados: CPF do paciente, CRM do médico" + botão **Corrigir dados**. Nunca erro técnico ( `interpolation_error: paciente.cpf undefined` ) |
| Na renderização | Nenhum placeholder cru pode sair no PDF final |

**Separação template × emissão**

- No **template**: estrutura fixa + campos automáticos + campo de texto livre.
- Na **emissão**: o sistema preenche nome, data, CRM etc. automaticamente e deixa o campo de texto livre para o médico escrever naquele momento (ex.: a prescrição).

**Fluxo de uso:** Templates → Novo template → escolher "Receita", "Laudo" ou "Documento personalizado" → editar a folha → inserir campos → visualizar → salvar.

**Renderização do PDF (back-end)**

- O template é persistido como **JSON do BlockNote**.
- Na emissão, o back-end (Elysia) converte o JSON em HTML com o mesmo CSS do editor, interpola os valores e renderiza o PDF (Chromium headless/Playwright), garantindo fidelidade WYSIWYG; o PDF é arquivado e o snapshot de valores é guardado (RF-C10).
- **[PENDENTE]** Validar Playwright/Chromium headless no runtime Bun (Épico 1); alternativa: worker Node dedicado só para render.

## Módulo D — Transcrição Inteligente de Anamnese (via Sintesy)

| ID | REQUISITO | PRIORIDADE |
|---|---|---|
| RF-D1 | Configuração prévia, pelo médico, dos campos e tópicos obrigatórios da anamnese (ex.: queixa, sintomas, medicamentos, conduta) | Must |
| RF-D2 | Captura de áudio no navegador (MediaRecorder), com filtro de redução de ruído via Web Audio API; saída **MP3**, limite de **500 MB** com truncamento controlado acima do limite. Ver Seção 3.4 | Must |
| RF-D3 | Transcrição do áudio pela **API B2B do Sintesy** ( `POST /sintesy/assistant/transcribe/` ), chamada server-to-server pelo back-end MedFlow, com credencial de aplicação/clínica | Must |

| | | |
|---|---|---|
| RF-D4 | Extração semântica direcionada **apenas** aos tópicos configurados (prompt engineering sobre o texto transcrito, no back-end MedFlow) — descartando conversas triviais | Must |
| RF-D5 | Interface de revisão rápida da transcrição estruturada e aprovação em 1 clique; texto aprovado entra no prontuário como anamnese do atendimento | Must |
| RF-D6 | A IA é estritamente **redatora** — nunca sugere diagnóstico nem decisão clínica | Must (restrição) |
| RF-D7 | Credenciais Sintesy vivem **apenas** no back-end; áudio nunca vai direto do navegador para o Sintesy | Must |
| RF-D8 | Pipeline assíncrono com estados visíveis (processando / concluído / falhou-reenviar); retry com backoff em falha do Sintesy | Must |
| RF-D9 | Texto transcrito + extração estruturada persistidos em JSONB, vinculados ao atendimento e ao médico | Must |
| RF-D10 | Registro do uso da integração (clínica, médico, atendimento, duração, modelo `stt-low`, custo estimado, status) para **medição de custo por clínica** — sem bloqueio de uso. Ver Seção 5.5 | Should |
| RF-D11 | **[Fora do MVP — fase futura]** Síntese completa Sintesy (mapa mental/checklist) vinculada ao atendimento. No MVP a integração usa apenas **transcrição**; se/quando ativado, usa **resumo + transcrição** | Could |
| RF-D12 | **Descartar o áudio original do MedFlow imediatamente após a transcrição bem-sucedida** (minimização de dado sensível — LGPD) | Must |

## 3.4 Detalhamento dos limites de áudio (RF-D2) — decidido

| ITEM | DECISÃO |
|---|---|
| Formato aceito | **MP3** |
| Tamanho máximo | **500 MB** por áudio |
| Acima de 500 MB | O MedFlow **corta o arquivo para 500 MB** e segue com a transcrição (não rejeita o atendimento) |
| Aviso | O profissional é avisado **antes** da transcrição: "O áudio excede o limite de 500 MB e será processado somente até o limite permitido." |
| Registro | O job guarda `originalSizeBytes`, `processedSizeBytes`, `truncated: true/false` |
| Onde validar | Validação no **navegador** (feedback imediato) **e** no **back-end** (fonte da verdade); o corte acontece **no back-end** |

| | |
|---|---|
| Áudio inválido | Arquivo corrompido/formato errado → erro amigável com botão de regravar; nunca erro técnico |

**Limite de duração:** decorre do tamanho (a duração máxima prática é validada no spike, item 2 da Seção 10.2).
**Risco assumido:** o corte pode interromper o áudio no meio de uma fala — por isso o aviso explícito e o registro do truncamento no atendimento.

### Módulo E — Segurança & Acessos

| ID | REQUISITO | PRIORIDADE |
|---|---|---|
| RF-E1 | Autenticação JWT **sem expiração** (decisão de produto); token invalidado apenas em troca de senha ou desativação do usuário | Must |
| RF-E2 | Controle de papéis (RBAC): médico (total) × recepcionista (agenda, cadastro e **leitura de Prescrições/Exames**) | Must |
| RF-E3 | Criptografia de dados sensíveis em repouso e trânsito (HTTPS/TLS) | Must |
| RF-E4 | Hashing de senhas com bcrypt | Must |
| RF-E5 | Auditoria de acessos e operações em dados clínicos (base da assinatura simples do RF-C7) | Must |
| RF-E6 | Conformidade LGPD para dados sensíveis de saúde (minimização, finalidade, titularidade) | Must |

## 4. Requisitos Não Funcionais

| ID | CATEGORIA | REQUISITO |
|---|---|---|
| RNF-1 | Confiabilidade | ACID estrito (SQlite) para prontuários eletrônicos |
| RNF-2 | Extensibilidade | Colunas JSONB para modelos customizáveis de anamnese e extração |
| RNF-3 | Usabilidade | Operações centrais da rotina clínica em no máximo 1 clique a partir da grade |
| RNF-4 | Performance | Interface reativa para grade de agenda; tipagem estática end-to-end (TypeScript) |
| RNF-5 | Segurança | HTTPS/TLS em toda comunicação; bcrypt; auditoria constante pelo QA |
| RNF-6 | Qualidade | CI/CD com verificação estática de tipos + testes unitários obrigatórios antes do deploy |
| RNF-7 | Privacidade | Tratamento de dado sensível de saúde conforme LGPD (art. 11) |

| | | |
|---|---|---|
| RNF-8 | Resiliência | Transcrição é job assíncrono — falha do Sintesy nunca derruba a consulta em andamento |
| RNF-9 | Tipo-safety de contrato | Contratos tipados (OpenAPI/Eden); cliente Sintesy isolado em módulo próprio |
| RNF-10 | Zero atrito no editor | O profissional nunca digita sintaxe, chave técnica ou expressão; toda inserção é por clique em catálogo |
| RNF-11 | Fidelidade de impressão | O PDF gerado no back-end deve reproduzir fielmente o preview A4 do editor |

# 5. Integração Sintesy — Mapa Técnico (núcleo da transcrição)

## 5.1 Visão geral

O MedFlow **não implementa STT próprio**. O fluxo de anamnese usa a plataforma Sintesy (api.sintesy.me) como serviço de transcrição, e o MedFlow faz a extração orientada a tópicos sobre o texto retornado.

```
[Navegador — consultório]
  MediaRecorder + Web Audio (filtro de ruído)
        │  upload do áudio (multipart)
        ▼
[Back-end MedFlow — Elysia]
  1. cria job Anamnese (status=processando) + áudio temporário (MP3 ≤ 500 MB; trunca se exceder)
  2. POST /sintesy/assistant/transcribe/  ──► [API B2B Sintesy]   (modelo stt-low)
  3. recebe { transcription: "..." }            (AssemblyAI → fallback DeepInfra)
  4. ExtractionProvider → gorouter: transcrição → JSON por tópicos configurados
  5. persiste transcrição + JSONB e DESCARTA o áudio (RF-D12)
        │  polling de status pelo front (no MedFlow)
        ▼
[Tela de revisão] → médico ajusta → aprova em 1 clique → vira anamnese do prontuário
```

## 5.2 Endpoints do Sintesy utilizados

| ENDPOINT | MÉTODO | USO NO MEDFLOW | OBSERVAÇÕES (VERIFICADAS NO CÓDIGO DA API) |
|---|---|---|---|
| `/auth/` | POST | [Fallback legado] Login de conta de usuário → token | Token-based com refresh automático; usado **apenas** enquanto a API B2B não estiver disponível |
| **API B2B — autenticação** | POST | **Auth da integração** (API key por aplicação/clínica → token de serviço) | Contrato novo no Sintesy (ADR-002); base para medir/cobrar por consumidor |
| **API B2B — uso** | GET | Consulta de consumo da chave (opcional, para conferência) | Complementa a medição local do MedFlow (RF-D10) |

| | | | |
|---|---|---|---|
| `/sintesy/assistant/transcribe/` | POST (multipart `audio`) | **STT do fluxo de anamnese** (modelo `stt-low`) | Síncrono; valida extensão e tamanho máx.; usa arquivo temporário **sem persistir o áudio**; retorna `{ transcription }`; falha de billing → 502 |
| `/upload/get-presigned-url/` | POST | Upload S3 de áudios grandes | Opcional; avaliar necessidade |
| `/sintesy/` | POST (multipart `audio_file`) | [Fase futura — RF-D11] síntese completa vinculada | Assíncrono; persiste áudio em S3; output fixo (resumo/mapa/checklist) |
| `/sintesy/{uuid}/` | GET | [Fase futura] polling da síntese | Mesmo padrão do dashboard Sintesy |
| `/sintesy/{uuid}/pdf/` · `/docx/` | GET | [Fora do MVP] export da síntese | Só em plano Pro |

## 5.3 Modelo de autenticação da integração — DECIDIDO: API B2B própria do Sintesy

O MedFlow **não** usará login de conta de pessoa física nem BYO por médico. O Sintesy passa a oferecer **API própria para integração B2B** (API key por aplicação/clínica), o que:

- desacopla o MedFlow do ciclo de vida de uma conta de usuário;
- permite **medir e cobrar por consumidor** (clínica/aplicação);
- habilita reuso por **outros produtos** (outros sistemas de clínica, parceiros, integrações internas) — a integração deixa de ser exclusiva do MedFlow;
- permite revogar/rotacionar credencial sem afetar usuários finais.

**Contrato mínimo da API B2B** (detalhar no ADR-002, responsável: Ruan):

| ITEM | REQUISITO |
|---|---|
| Autenticação | API key/credencial de serviço (header), com escopo e identificação do consumidor |
| Identificação | Chave vinculada a uma **clínica/organização** consumidora (não a uma pessoa) |
| Uso | Medição por requisição: duração, modelo, status, custo estimado, `request_id` |
| Modelo | Seleção do modelo de transcrição (`stt-low` no MedFlow) por requisição ou por chave |
| Limites | **Sem bloqueio por quota no MVP** (ver 5.5); o MedFlow apenas mede |
| Erros | Respostas padronizadas (código estável + mensagem) para retry/backoff previsível |
| Revogação | Rotação/revogação de chave sem downtime para o consumidor |

**Plano de transição (obrigatório para não travar o cronograma):** enquanto a API B2B não estiver pronta no Sintesy, o MedFlow usa **conta de serviço por clínica** com o **cliente Sintesy isolado em módulo próprio**

( `SintesyClient` ) — a troca de auth não pode tocar o pipeline clínico. **Mock do Sintesy** obrigatório para dev, testes e demonstração.

| OPÇÃO | SITUAÇÃO |
|---|---|
| A. Conta de serviço por clínica | **Fallback temporário** até a API B2B existir |
| B. Cada médico conecta a própria conta | **Descartada** |
| C. **API key B2B no Sintesy** | **Decidida** (requer desenvolvimento no Sintesy) |

## 5.4 Extração de tópicos (responsabilidade do MedFlow)

- Input: `transcription` (texto cru) + tópicos configurados pelo médico (RF-D1).
- Prompt estruturado com schema JSON estrito — apenas os tópicos configurados, `null` quando ausente, descarte de conversa trivial, proibição explícita de sugestão diagnóstica (RF-D6).
- Output: JSON por tópico (ex.: `{queixa, sintomas, medicamentos, conduta}` ) em JSONB (RNF-2).
- **Provedor do LLM — DECIDIDO: gorouter** (combo próprio do projeto), acessado por uma abstração interna `ExtractionProvider` :

```
MedFlow → ExtractionProvider → gorouter → (modelo escolhido)
```

- O código clínico **não** conhece o fornecedor: trocar de modelo é configuração, não refatoração.
- Critérios de aceitação do provider: JSON válido conforme schema, boa qualidade em PT-BR, latência aceitável e custo controlado.
- Nota: a IA do Sintesy ( `/sintesy/ask/` ) opera sobre sínteses da conta — não serve para extração estruturada arbitrária.
- **Restrições do prompt (inegociáveis, RF-D6):** apenas redatora; só os tópicos configurados; `null` quando a informação não aparecer; descarte de conversa trivial; **proibido** sugerir diagnóstico ou conduta; saída validada pelo back-end antes de persistir.

## 5.5 Quotas, custo e limites — DECIDIDO: medir, não limitar

- **Modelo de transcrição:** `stt-low` (mais leve) em todas as chamadas do MedFlow.
- **Sem limite/bloqueio de uso no MVP.** O sistema **mede o custo por clínica** e exibe o consumo ao administrador; não bloqueia a rotina clínica por quota.
- **O que é registrado por transcrição (RF-D10):** clínica · médico · atendimento · data/hora · duração do áudio · modelo ( `stt-low` ) · status do job · `request_id` do Sintesy · custo estimado · erro (quando houver).
- **Painel simples:** "Uso este mês: 86 min · custo estimado R$ X" por clínica; alerta administrativo quando o consumo foge do padrão (não é bloqueio).
- **Cobrança:** fora do MVP. A medição é a base para decidir depois entre repasse integral, margem, preço fixo por clínica ou cobrança por minuto.
- **B2B:** com a API B2B (5.3) o consumo passa a ser medido também do lado do Sintesy, permitindo conferência e faturamento por consumidor.
- Latência: transcrição síncrona; anamneses de 10–15 min podem levar dezenas de segundos → job assíncrono com polling do front **no MedFlow**.
- Idempotência: o endpoint não aceita id do cliente — o MedFlow gera o `anamnese_id` antes de enviar e controla retry/dedupe.

### 5.6 LGPD e fluxo de dados sensíveis

| ASPECTO | DECISÃO |
|---|---|
| Natureza do dado | Dado sensível de saúde (art. 11 LGPD) |
| Papéis | Clínica = controladora; MedFlow = processador; Sintesy = subprocessador (STT) |
| Áudio original | **Descartado pelo MedFlow imediatamente após a transcrição bem-sucedida (RF-D12)** ; o endpoint do Sintesy também não retém (arquivo temporário) |
| Texto transcrito | Permanece no SQlite do MedFlow (criptografado em repouso); log de auditoria em todo acesso |
| Transparência | **[PENDENTE: redigir termo/aviso]** informando o uso de IA de transcrição à clínica/paciente |
| Minimização | Extração guarda apenas os tópicos configurados; conversa trivial descartada |

### 5.7 Tratamento de erros da integração

| CENÁRIO | COMPORTAMENTO MEDFLOW |
|---|---|
| 502 do Sintesy (billing/falha de provider) | Retry com backoff (3 tentativas); depois status `falhou` com botão "reenviar" |
| Timeout de transcrição | Job assíncrono isola; consulta continua (RNF-8) |
| Credencial expirada | Refresh automático; falha de login → alerta ao admin da clínica |
| Áudio inválido | Validação no navegador **e** no back-end (formato MP3, limite 500 MB — Seção 3.4); erro amigável com botão de regravar |
| Áudio acima de 500 MB | Back-end **trunca para 500 MB**, avisa o profissional e grava `truncated: true` no job |
| Sintesy fora do ar | Degradação graciosa: digitação manual da anamnese |

## 6. Épicos

### ÉPICO 1 — Fundação & Setup de Engenharia

**Objetivo:** ambiente, pipelines e base arquitetural prontos para desenvolvimento.

- Setup monorepo: **ElysiaJS (Bun)** (API) + **React (Vite) + Tailwind + BlockNote** (SPA).
- Pipeline CI/CD (GitHub Actions): lint, type-check, testes, build Docker.
- Containers Docker padronizados (dev/prod) + **container do WAHA**.

- Schema Prisma inicial: Usuário, Paciente, Agenda, Atendimento, Anamnese, **TemplateDocumento, DocumentoEmitido**, Anexo, Auditoria, **SintesyB2BCredential** (credencial B2B por clínica/aplicação), TranscriptionJob (**com uso e custo medidos**), **WhatsappSession** (1:1 com Clínica) e **MensagemWhatsapp** (fila e estados).
- OpenAPI + Eden Treaty para type-safety frontback.
- **[PENDENTE]** Validar Prisma e Playwright/Chromium headless sobre Bun (alternativas: Drizzle; worker Node só para o PDF).
- Critério de aceite: pipeline verde, build Docker executável, schema versionado.

## ÉPICO 2 — Autenticação, Papéis e Auditoria (RF-E1–E6)

**Objetivo:** base de segurança antes de qualquer dado clínico.

- Login JWT **sem expiração** (invalidado em troca de senha/desativação do usuário).
- RBAC: médico (total) × recepcionista (agenda, cadastro e leitura de Prescrições/Exames).
- Middleware de auditoria de acessos a dados sensíveis.
- Critério de aceite: recepcionista baixa prescrição e exames, mas não acessa anamnese/evolução; tentativa bloqueada é registrada em log; testes E2E demonstrando.

## ÉPICO 3 — Gestão de Agenda (RF-A1–A9)

**Objetivo:** núcleo operacional — a "tela principal" da clínica.

- Grade diária/semanal com slots e status visuais.
- CRUD de agendamentos, bloqueios e encaixes.
- Travas transacionais anti-sobreposição no SQlite.
- Atalho 1 clique → Ficha do Paciente.
- **WhatsApp via WAHA** (RF-A8, Seção 3.1): **1 sessão por clínica**, conexão por QR code com sessão persistente, envio de lembrete, webhook de resposta atualizando o status, interpretação por palavras-chave (SIM/1/CONFIRMO… × NÃO/2/CANCELAR…), fila de "aguardando confirmação manual", estados de mensagem ( `pendente/enviando/enviada/falhou` ) e painel de estado da sessão (conectado/desconectado/aguardando QR).
- Critério de aceite: dois agendamentos simultâneos no mesmo slot são rejeitados pelo banco mesmo sob concorrência; resposta "sim" no WhatsApp muda o status na grade sem intervenção humana.

## ÉPICO 4 — Ficha do Paciente & Prontuário (RF-B1–B5)

**Objetivo:** centralização 360°.

- Cadastro e **busca livre/incremental** de pacientes (Seção 3.2): nome (parcial, sem acentos/caixa), CPF e telefone normalizados, com índices.
- Linha do tempo de atendimentos com evolução.
- Upload de anexos PDF/JPG.
- Critério de aceite: a partir da grade, chega-se em ≤1 clique à ficha com histórico completo e anexos listados.

## ÉPICO 5 — Templates & Emissão de Documentos (RF-C1–C10)

**Objetivo:** documentação clínica padronizada, com editor sem atrito.

- **Editor BlockNote** (RF-C1): folha A4, blocos, texto rico, alinhamento, cabeçalho/rodapé, divisores, logo.
- **Catálogo de campos** (RF-C2): botão "Inserir campo automático", chips visuais, metadados tipo/obrigatório; persistência em `{{entidade.campo}}` invisível ao usuário.

- **Validação** (Seção 3.3): status "Template com erro" ao salvar; bloqueio amigável com lista de dados faltantes + "Corrigir dados" na emissão; preview com paciente fictício (RF-C9).
- **Campo de texto livre** (RF-C8) preenchido na emissão.
- **Renderizador PDF no back-end**: BlockNote JSON → HTML → PDF (Chromium headless), fidelidade WYSIWYG (RNF-11).
- **Snapshot imutável** do documento emitido (RF-C10) + assinatura simples com nome/CRM e auditoria (RF-C7).
- Tipos de documento: Receita (simples e controlados), Laudo, Documento personalizado.
- Critério de aceite: médico cria um receituário do zero sem digitar sintaxe; emissão com CPF faltante é bloqueada com mensagem amigável; PDF sai idêntico ao preview; editar o template depois não altera documento já emitido.

### ÉPICO 6 — Transcrição Inteligente via Sintesy (RF-D1–D12)

**Objetivo:** reduzir digitação durante a consulta, com STT do Sintesy e extração própria.

- **Configuração de tópicos** (RF-D1): modelo de anamnese customizável por médico (JSONB).
- **Captura no front** (RF-D2/Seção 3.4): MediaRecorder + filtro Web Audio; saída **MP3**, limite **500 MB** (validação no navegador e no back-end; truncamento no back-end com aviso e registro).
- **Cliente Sintesy** (RF-D3/D7): módulo isolado `SintesyClient` — **auth B2B (API key por clínica)**, com fallback temporário de conta de serviço; chamada a `/sintesy/assistant/transcribe/` com modelo `stt-low`; retries com backoff (RF-D8).
- **Pipeline de job** (RF-D8/RNF-8): `TranscriptionJob` com estados; polling do front no MedFlow; reenvio manual.
- **Medição de uso** (RF-D10/Seção 5.5): registro por clínica/atendimento (duração, modelo, custo estimado, status) e painel de consumo — **sem bloqueio de quota**.
- **Descarte do áudio** (RF-D12) após transcrição bem-sucedida.
- **Extração por tópicos** (RF-D4/D6): `ExtractionProvider` → **gorouter**, prompt com schema JSON estrito e validação da saída.
- **Revisão e aprovação** (RF-D5): transcrição extração lado a lado, edição inline, aprovação em 1 clique → anamnese no atendimento (RF-D9).
- Critério de aceite: áudio de teste com small talk gera apenas os tópicos configurados; falha simulada do Sintesy deixa o job reenviável sem perder o atendimento; o áudio não existe mais no storage após sucesso; **áudio acima de 500 MB é truncado com aviso e registro**; **o consumo aparece no painel por clínica (sem bloqueio)**; IA não emite opinião diagnóstica.

### ÉPICO 7 — Homologação, LGPD e Qualidade Final (RF-E5–E6, RNF-6–7)

**Objetivo:** sistema auditável pronto para a banca (AV2).

- Testes E2E (QA) — incluindo transcrição (Sintesy real e mock), emissão/PDF e fluxo WhatsApp.
- Auditoria de segurança + validação LGPD (incl. descarte do áudio e permissões da recepção).
- Homologação com usuário real (clínica parceira) e aceite formal.
- Matriz de bugs fechada; demonstração ao vivo confiável.

---

## 7. Roadmap por Marco Avaliativo

| PERÍODO | MARCO | ÉPICOS | ENTREGAS |
|---|---|---|---|

| | | | |
|---|---|---|---|
| 11/09–30/09 | Fase 2: Prototipação & Modelagem | 1 (início) | Telas Figma da Agenda e Ficha; schema Prisma + contratos; CI/CD inicial; **spike da integração Sintesy (ADR-002, incl. contrato da API B2B e fallback de conta de serviço) e do renderizador PDF (ADR-003)** |
| 01/10–22/10 | **Status Report II — Core do Sistema** | 1, 2, 3, 4 (parcial) | Agenda funcional (grade, status, encaixes); Ficha + histórico; plano de testes; **justificativa formal das mudanças pós-AV1** |
| 23/10–15/11 | Fase 4: Módulos Clínicos | 4 (final), 5, 6 | **Editor BlockNote + emissão/PDF + assinatura simples**; pipeline de transcrição via Sintesy; **WhatsApp/WAHA**; refinamento 1 clique |
| 16/11–30/11 | **Status Report III — Homologação & Testes** | 7 (+ restauros de 5/6) | E2E pelo QA (incl. integrações); homologação e aceite da clínica; auditoria de segurança e LGPD |
| 01/12–15/12 | **Entrega Final AV2** | — | Demonstração ao vivo; relatório final de extensão; seminário |

## 8. Riscos e Mitigações

| RISCO | IMPACTO | MITIGAÇÃO |
|---|---|---|
| Ruído em gravações de áudio no consultório | Médio | Filtro de redução de ruído (Web Audio API) + prompts com descarte de conversa trivial |
| Inconsistência em horários de agendamento | Alto | Travas transacionais no PostgreSQL, não apenas validação na aplicação |
| Atraso no cronograma das sprints | Médio | Acompanhamento do Scrum Master + priorização MoSCoW estrita |
| Vazamento de dados clínicos sensíveis | **Crítico** | HTTPS/TLS, bcrypt, auditoria pelo QA; descarte do áudio (RF-D12); fluxo mapeado na Seção 5.6 |
| Indisponibilidade da API Sintesy | Médio | Job assíncrono com retry/backoff; degradação graciosa; **mock do Sintesy** para dev e demonstração |
| Custo da API Sintesy estourar (não há bloqueio de quota no MVP) | Médio | Medição por clínica (RF-D10/Seção 5.5) + painel de consumo com alerta administrativo; modelo `stt-low`; medição também do lado do Sintesy via API B2B |
| Dependência da **API B2B do Sintesy** (contrato novo, ainda inexistente) | **Alto** | `SintesyClient` isolado + fallback de conta de serviço + mock; ADR-002 com o contrato mínimo antes de fechar o Épico 6 |
| Truncamento de áudio acima de 500 MB perder conteúdo clínico | Médio | Aviso antes da transcrição, registro de `truncated` no atendimento e possibilidade de gravar em partes |

| | | |
|---|---|---|
| **Ban do número de WhatsApp do profissional (WAHA usa API não oficial)** | **Alto** | Número dedicado da clínica em vez do pessoal; ritmo de envio conservador (sem disparo em massa); aquecimento do número; sessão persistente para evitar re-scan de QR; plano B documentado: WhatsApp Cloud API oficial |
| WAHA cair e perder a sessão (exige novo QR) | Médio | Monitoramento da sessão + aviso no painel para reconectar; fila de mensagens não enviadas |
| Fidelidade do PDF divergir do editor | Médio | Mesmo CSS no editor e no render; testes de regressão visual no QA; ADR-003 |
| **Mudanças pós-AV1 questionadas pela banca** | Médio | Justificativa formal no Status Report II (tabela do registro de alterações) |

# 10. Decisões

## 10.1 Fechadas (equipe, pós-AV1)

| # | TEMA | DECISÃO |
|---|---|---|
| 1 | Assinatura de documentos | **Eletrônica simples**: identificação do autor (nome + CRM) no PDF, registro de autor/data/hora e log de auditoria. Sem ICP-Brasil e sem hash/QR no MVP |
| 2 | Editor de templates | **BlockNote**: editor visual de blocos, folha A4, texto rico, alinhamento, cabeçalho/rodapé, divisores, logo e preview fiel. Sem posicionamento livre tipo Canva |
| 3 | Placeholders | Sintaxe interna `{{entidade.campo}}`, **gerada pelo editor** — o usuário só usa chips do catálogo. Catálogo fechado por grupo (Paciente/Médico/Atendimento/Clínica) |
| 4 | Campos obrigatórios | Metadados por campo (`tipo`, `obrigatorio`). Obrigatório vazio bloqueia a emissão com mensagem amigável + "Corrigir dados"; opcional vazio simplesmente não aparece |
| 5 | Validação de template | Placeholder inválido → status **"Template com erro"**, inutilizável até correção. Preview com paciente fictício |
| 6 | Geração de PDF | **No back-end**: BlockNote JSON → HTML → PDF (Chromium headless), com snapshot imutável do documento emitido |
| 7 | Template × emissão | Template guarda estrutura fixa + campos automáticos + **campo de texto livre** preenchido na emissão |
| 8 | Permissões da recepção | **Leitura de Prescrições e Exames** (para baixar/enviar ao paciente); sem acesso a anamnese/ evolução clínica |
| 9 | Sessão | **JWT sem expiração** (simplicidade); invalidado em troca de senha ou desativação do usuário |

| | | |
|---|---|---|
| 10 | Confirmação de consulta (RF-A8) | **WhatsApp via WAHA self-hosted**, **1 sessão por clínica** conectada por QR code, com número **dedicado da clínica** (não o pessoal do profissional). Sem SMS, sem gateway pago, sem "webhook gratuito" |
| 11 | Áudio da consulta | **Descartado** do MedFlow imediatamente após a transcrição bem-sucedida (LGPD) |
| 12 | Auth da integração Sintesy | **API B2B própria do Sintesy** (API key por aplicação/clínica). Conta de serviço por clínica é **apenas fallback temporário**; BYO por médico descartado |
| 13 | LLM de extração de tópicos | **gorouter**, acessado por `ExtractionProvider` (troca de modelo sem refatorar o pipeline) |
| 14 | Quota e medição | **Sem bloqueio de quota no MVP**: mede **custo por clínica**; transcrição no modelo `stt-low`; painel de consumo; cobrança fora do MVP |
| 15 | RF-D11 (síntese completa) | **Fora do MVP**. A integração usa apenas **transcrição**; se reativada, apenas **resumo + transcrição** |
| 16 | Limites de áudio | **MP3, até 500 MB**; acima disso o back-end **trunca para 500 MB**, avisa o profissional e registra `truncated: true` |
| 17 | Busca de pacientes (RF-B5) | **Livre e incremental** (LIKE parcial), ignora acentos e caixa, resultados enquanto digita (debounce 250–300 ms); CPF e telefone normalizados (só dígitos), CPF mascarado na lista |
| 18 | WhatsApp (WAHA) | **1 sessão por clínica**, número dedicado da clínica; respostas por **palavras-chave com variações** (SIM/1/CONFIRMO… × NÃO/2/CANCELAR…); ambíguas → fila de confirmação manual; painel de estado + fila de pendentes + plano B (WhatsApp Cloud API) |
| 19 | Catálogo de campos dos templates | Catálogo completo (**essenciais obrigatórios** + complementares opcionais), com obrigatoriedade definida **por tipo de documento** |